Group by y Summarise

X Clases Spark R

Alex bajaña

2019-03-21



group by y summarise son herramientas para analizar los datos de en grupos ¡de cualquier tamaño!.

Ventajas:

- Similar al uso de GROUP BY en SQL.
- Mismas variantes que mutate

Empecemos

Funciones auxiliares

Tipo	Funciones	Descripción
Basicas	mean()	Media de un vector
Basicas	median()	Mediana de un vector
Basicas	sum()	Suma de elementos
Variaciones	sd()	Desviación standar
Variaciones	IQR()	Rango Interquantilico
Rangos	min()	Mínimo
Rangos	max()	Máximo
Rangos	quantile()	Cuantiles
Posición	first()	Primer elemento en el grupo
Posición	last()	Último elemento en el grupo
Posición	nth()	Elemento que se úbica en la posición n-sima
Conteo	n()	Número de filas
Conteo	n_distinct()	Número de elementos distintos

Datos

```
library(datasets)
library(tibble)

data <- datasets::Titanic

data <- data %>% as.tibble()

data %>% head(6) %>% kable("html")
```

Class	Sex	Age	Survived	n
1st	Male	Child	No	0
2nd	Male	Child	No	0
3rd	Male	Child	No	35
Crew	Male	Child	No	0
1st	Female	Child	No	0
2nd	Female	Child	No	0

summarise ¿con o sin group_by?

Con group_by

```
data %>%
  group_by(Class) %>%
  summarise(mean_personas = sum(n)) %>%
  kable("html")
```

Class	mean_personas
1st	325
2nd	285
3rd	706
Crew	885

summarise ¿con o sin group_by?

Sin group_by

```
data %>%
  summarise(mean_personas = sum(n)) %>%
  kable("html")
```

mean_personas

2201

summarise_at

De forma similar que en los mutate se puede agregar variables llamando el vector de nombres de columas.

Summarise_at

Resultado

Class	Survived	n	Inc
1st	No	30.50	5043.270
1st	Yes	50.75	5049.033
2nd	No	41.75	1390.525
2nd	Yes	29.50	1388.815
3rd	No	132.00	950.030
3rd	Yes	44.50	960.215
Crew	No	168.25	560.255
Crew	Yes	53.00	596.655

Se observa que el ingreso no difiere en promedio entre las distintas clases de tickets, asi mismo se ve que los no sobrevivientes al hundimiento del Titanic se encuentran en las clases tercera y personal.

summarise_if

Evaluar un predicado y colapsar aquellas variables que cumplen la condicion

Summarise_if

Resultados

	Sex		Age		n_ma	X	n_min	n_	sd	n_Q25	n_Q50	n_Q	75
	Fem	nale	Adu	lt	14	10	3	50.3031	88	10.75	48.0	82.2	25
Female		nale	Chil	d	1	17	0	7.5769	86	0.00	0.5	13.2	25
	Mal	e	Adu	lt	67	70	14	218.7241	82	70.50	136.0	240.	75
	Mal	e	Chil	d	3	35	0	12.1184	63	0.00	2.5	11.5	50
Sex		Age	e Ir	ıc_	_max	Ir	nc_min	Inc_sd	Ir	ıc_Q25	Inc_Q5	0 In	c_Q 7
Fen	nale	Adu	ılt :	50	61.24		566.37	1904.860	85	1.3650	1194.66	0 23	26.20
Fen	nale	Chil	ld :	50	57.60		554.61	1914.482	84	1.5625	1147.63	0 22	89.63
Mal	e	Adu	ılt	50	42.68		569.75	1904.536	86	4.6575	1178.32	5 23	21.85
Mal	e	Chil	ld :	50	67.41		536.64	1915.204	87	2.8700	1169.26	0 23	00.93



La similitud con mutate supera los 9000!

